Nota Metodologica sul modello ZISAR

Zero-Inflated Spatial Autoregressive Model

Niccolò Salvini

Marzo 2026 — Documento interno per i coautori

1 Idea di fondo

Abbiamo dati di conteggio spaziali (es. accessi al pronto soccorso per comune) con due problemi simultanei:

1. **Eccesso di zeri**: molti comuni registrano zero accessi, più di quanti un Poisson o un NB possano spiegare.
2. **Dipendenza spaziale**: comuni vicini hanno conteggi simili, indipendentemente dalle covariate.

Nessun modello standard gestisce entrambi. Il ZINB ignora lo spazio; il SAR ignora gli zeri. Il ZISAR li combina introducendo un campo latente autoregressivo $\boldsymbol{\eta}$ che guida la media dei conteggi.

2 Architettura del modello, passo per passo

2.1 Layer 1: il campo latente spaziale η

Il cuore del modello è un'equazione autoregressiva simultanea (SAR) sullo spazio, scritta come:

$$\eta_i = \rho \sum_{j=1}^{n} w_{ij}\, \eta_j + \mathbf{x}_i' \boldsymbol{\beta} + u_i, \qquad u_i \sim N(0, \sigma^2), \tag{1}$$

dove w_{ij} sono i pesi spaziali (es. contiguità queen, standardizzata per riga), $\rho \in (-1, 1)$ è il parametro autoregressivo spaziale, e u_i è un effetto random individuale.

Esempio numerico. Prendiamo 4 comuni su una griglia 2×2:

$$\mathbf{W} = \begin{pmatrix} 0 & 1/2 & 1/2 & 0 \\ 1/2 & 0 & 0 & 1/2 \\ 1/2 & 0 & 0 & 1/2 \\ 0 & 1/2 & 1/2 & 0 \end{pmatrix}.$$

Ogni comune ha un solo vicino a est e uno a sud (queen semplificata). Con $\rho = 0.4$, $\boldsymbol{\beta} = (1, 0.5)'$ (intercetta + una covariata x), $x = (0, 1, -1, 0.5)'$, e $\mathbf{u} = (0.1, -0.2, 0.3, 0)'$, l'equazione in forma vettoriale è:

$$(\mathbf{I} - 0.4\,\mathbf{W})\,\boldsymbol{\eta} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}.$$

Forma ridotta. Risolvendo per $\boldsymbol{\eta}$:

$$\boldsymbol{\eta} = \underbrace{(\mathbf{I} - \rho\,\mathbf{W})^{-1}}_{\mathbf{S}(\rho)}\,(\mathbf{X}\boldsymbol{\beta} + \mathbf{u}). \tag{2}$$

La matrice $\mathbf{S}(\rho) = (\mathbf{I} - \rho\mathbf{W})^{-1}$ è il **moltiplicatore spaziale**. Tramite la serie di potenze $\mathbf{S}(\rho) = \mathbf{I} + \rho\mathbf{W} + \rho^2\mathbf{W}^2 + \cdots$, si vede che:

- il termine $\mathbf{I}$ = effetto diretto (il comune su sé stesso),
- $\rho\mathbf{W}$ = effetto dei vicini diretti,
- $\rho^2\mathbf{W}^2$ = effetto dei "vicini dei vicini",
- e così via, con peso decrescente come ρ^s.

Uno shock su un comune si **propaga** ai vicini, con intensità governata da ρ.

Calcolo esplicito (2×2). Con i valori sopra, $\mathbf{X}\boldsymbol{\beta} + \mathbf{u} = (1.1, 1.3, 0.8, 1.25)'$. Calcoliamo:

$$\mathbf{I} - 0.4\mathbf{W} = \begin{pmatrix} 1 & -0.2 & -0.2 & 0 \\ -0.2 & 1 & 0 & -0.2 \\ -0.2 & 0 & 1 & -0.2 \\ 0 & -0.2 & -0.2 & 1 \end{pmatrix}.$$

Invertendo (con un software, o osservando che la matrice ha struttura a blocchi):

$$\boldsymbol{\eta} \approx (1.29,\ 1.52,\ 1.07,\ 1.46)'.$$

Si noti come $\eta_2 = 1.52 > 1.3$: il valore è "gonfiatö' rispetto a $\mathbf{X}\boldsymbol{\beta} + u$ perché il comune 2 è vicino a comuni con valori alti. Questo è esattamente l'effetto della dipendenza spaziale.

2.2 Layer 2: dalla latente al conteggio

Il campo latente governa la **media condizionale** del conteggio tramite il link esponenziale:

$$\mu_i = \exp(\eta_i). \tag{3}$$

Con $\boldsymbol{\eta} \approx (1.29, 1.52, 1.07, 1.46)'$ otteniamo $\boldsymbol{\mu} \approx (3.63, 4.57, 2.92, 4.31)'$. Questi sono i "tassi attesi"; il conteggio osservato viene poi dalla binomiale negativa:

$$y_i \mid \eta_i,\, s_i = 0 \;\sim\; \mathrm{NB}(\mu_i, \kappa),$$

dove $\kappa > 0$ è il parametro di *shape*. Maggiore è κ, minore è l'overdispersion; al limite $\kappa \to \infty$ si riduce al Poisson. In pratica, κ tipicamente vale tra 0.5 e 10.

La varianza condizionale è:

$$\mathrm{Var}[y_i \mid \eta_i, s_i = 0] = \mu_i + \frac{\mu_i^2}{\kappa}.$$

Per $\mu_i = 4.57$ e $\kappa = 2$: $\mathrm{Var} = 4.57 + 4.57^2/2 = 4.57 + 10.44 = 15.01$. Molto più di μ, il che giustifica la NB rispetto al Poisson.

2.3 Layer 3: la zero-inflation

Oltre alla media del conteggio, introduciamo un meccanismo di **zeri strutturali** tramite un indicatore latente:

$$s_i \sim \mathrm{Bernoulli}(\pi_i), \qquad \mathrm{logit}(\pi_i) = \mathbf{z}_i'\boldsymbol{\gamma}.$$

Se $s_i = 1$, il comune i registra $y_i = 0$ *indipendentemente* dal tasso μ_i (assenza strutturale). Se $s_i = 0$, il conteggio viene dalla NB.

L'osservazione finale è quindi:

$$y_i = \begin{cases} 0 & \text{con probabilità } \pi_i \quad \text{(zero strutturale)}, \\ \mathrm{NB}(\mu_i, \kappa) & \text{con probabilità } 1 - \pi_i \quad \text{(conteggio)}. \end{cases}$$

Esempio. Se $\gamma = (-1, 0.4)'$ e $z_i = 0.5$, allora $\text{logit}(\pi_i) = -1 + 0.4 \times 0.5 = -0.8$ e $\pi_i = 1/(1 + e^{0.8}) \approx 0.31$. Vuol dire che il comune i ha il 31% di probabilità di produrre uno zero strutturale, *a prescindere* dal suo tasso μ_i.

La probabilità complessiva di osservare $y_i = 0$ è:

$$P(y_i = 0) = \pi_i + (1 - \pi_i) \left(\frac{\kappa}{\kappa + \mu_i} \right)^{\kappa}.$$

Il primo addendo sono gli zeri strutturali; il secondo gli zeri "di campionamento" (la NB può comunque dare zero).

Con $\pi_i = 0.31$, $\mu_i = 4.57$, $\kappa = 2$:

$$P(y_i = 0) = 0.31 + 0.69 \times \left(\frac{2}{6.57} \right)^2 = 0.31 + 0.69 \times 0.093 = 0.31 + 0.064 = 0.374.$$

Circa il 37% di probabilità di osservare zero, di cui il 31% è strutturale.

2.4 Riepilogo: il flusso generativo completo

1. Fisso le covariate $\mathbf{X}$, $\mathbf{Z}$, la matrice spaziale $\mathbf{W}$.
2. Genero gli effetti random: $u_i \sim N(0, \sigma^2)$.
3. Calcolo il campo latente: $\boldsymbol{\eta} = (\mathbf{I} - \rho \mathbf{W})^{-1} (\mathbf{X}\boldsymbol{\beta} + \mathbf{u})$.
4. Ottengo le medie: $\mu_i = \exp(\eta_i)$.
5. Calcolo le probabilità di zero strutturale: $\pi_i = \text{logit}^{-1}(\mathbf{z}_i' \gamma)$.
6. Per ogni comune: con probabilità π_i pongo $y_i = 0$; altrimenti genero $y_i \sim \text{NB}(\mu_i, \kappa)$.

I parametri da stimare sono: $\boldsymbol{\beta}$ (effetti covariate), ρ (dipendenza spaziale), γ (zero-inflation), κ (overdispersion NB), σ^2 (varianza effetti random).

3 Perché SAR sulla latente e non su y?

L'alternativa classica sarebbe:

$$\log(\mu_i) = \mathbf{x}_i' \boldsymbol{\beta} + \rho \sum_j w_{ij} y_j + v_i.$$

Qui y_j appare sia come outcome che come regressore $\Rightarrow$ **endogeneità**. Per stimarlo servono variabili strumentali (Lambert 2010), con tutti i problemi annessi (strumenti deboli, inconsistenza in piccoli campioni).

Nel ZISAR, la SAR opera sulla **latente** $\boldsymbol{\eta}$:

$$\boldsymbol{\eta} = \rho \mathbf{W}\boldsymbol{\eta} + \mathbf{X}\boldsymbol{\beta} + \mathbf{u}.$$

Non c'è endogeneità perché $\boldsymbol{\eta}$ non è osservato. Si può fare ML direttamente. Inoltre, si conserva la decomposizione LeSage-Pace degli effetti (diretti/indiretti/totali), che è il punto forte della spatial econometrics.

Analogia con il SAR lineare. Nel SAR lineare $\mathbf{y} = \rho\mathbf{W}\mathbf{y} + \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$ la forma ridotta è $\mathbf{y} = (\mathbf{I} - \rho\mathbf{W})^{-1}(\mathbf{X}\boldsymbol{\beta} + \mathbf{u})$, identica nella struttura alla nostra (**??**). La differenza è che nel ZISAR la SAR opera su $\boldsymbol{\eta}$ (lo spazio *latente*), non su $\mathbf{y}$ (lo spazio *osservato*). Dopo la trasformazione $\mu = \exp(\eta)$, la non-linearità spezza la simmetria, ma la logica degli spillover resta uguale.

4 Stima: TMB e approssimazione di Laplace

4.1 Il problema

La verosimiglianza marginale richiede di integrare fuori il campo latente $\boldsymbol{\eta}$:

$$L(\boldsymbol{\theta}) = \int_{\mathbb{R}^n} \underbrace{\prod_{i=1}^{n} f(y_i \mid \eta_i, \pi_i, \kappa)}_{\text{likelihood dati}|\boldsymbol{\eta}} \cdot \underbrace{p(\boldsymbol{\eta} \mid \boldsymbol{\beta}, \rho, \sigma^2)}_{\text{prior SAR su } \boldsymbol{\eta}} \, \mathrm{d}\boldsymbol{\eta}.$$

L'integrale è in n dimensioni (una per ogni unità spaziale). Non ha forma chiusa perché la NB è non-lineare in η.

4.2 L'approssimazione di Laplace

L'idea è semplice: espandiamo l'integranda attorno al suo **modo** (il massimo rispetto a $\boldsymbol{\eta}$) al second'ordine, ottenendo un integrale gaussiano che si calcola in forma chiusa.

Definiamo la **negative log-joint**:

$$f(\boldsymbol{\eta}; \boldsymbol{\theta}) = -\sum_{i=1}^{n} \log f(y_i \mid \eta_i, \pi_i, \kappa) - \log p(\boldsymbol{\eta} \mid \boldsymbol{\beta}, \rho, \sigma^2).$$

Sia $\hat{\boldsymbol{\eta}}(\boldsymbol{\theta}) = \arg\min_{\boldsymbol{\eta}} f(\boldsymbol{\eta}; \boldsymbol{\theta})$ il modo condizionale, e $\mathbf{H} = \nabla^2_{\boldsymbol{\eta}} f\big|_{\hat{\boldsymbol{\eta}}}$ l'Hessiano (matrice $n \times n$).

L'approssimazione di Laplace dà:

$$\log L(\boldsymbol{\theta}) \approx -f(\hat{\boldsymbol{\eta}}; \boldsymbol{\theta}) + \tfrac{n}{2}\log(2\pi) - \tfrac{1}{2}\log\det(\mathbf{H}). \tag{4}$$

Cosa sono i tre pezzi?

1. $-f(\hat{\boldsymbol{\eta}})$: la log-verosimiglianza congiunta nel punto di massimo.
2. $\frac{n}{2}\log(2\pi)$: costante normalizzante della gaussiana.
3. $-\frac{1}{2}\log\det(\mathbf{H})$: penalizzazione per la "curvatura" — misura quanto è concentrata la distribuzione di $\boldsymbol{\eta}$ attorno al modo.

4.3 Struttura dell'Hessiano

L'Hessiano ha due contributi:

$$\mathbf{H} = \underbrace{\frac{1}{\sigma^2}(\mathbf{I} - \rho\mathbf{W})'(\mathbf{I} - \rho\mathbf{W})}_{\text{da prior SAR}} + \underbrace{\operatorname{diag}(d_1, \ldots, d_n)}_{\text{da likelihood dati}},$$

dove $d_i = -\partial^2 \log f(y_i \mid \eta_i)/\partial\eta_i^2 > 0$.

Il punto cruciale è che $\mathbf{H}$ è **sparso**: la parte SAR ha lo stesso pattern di non-zeri di $\mathbf{W}'\mathbf{W}$, e la parte dati è diagonale. Questo permette di fattorizzare $\mathbf{H}$ tramite Cholesky sparso in tempo quasi-lineare in n, anziché $O(n^3)$.

4.4 Il log-determinante della SAR

La prior SAR su $\boldsymbol{\eta}$ contiene il termine $|\det(\mathbf{I} - \rho\mathbf{W})|$. Calcolarlo direttamente costerebbe $O(n^3)$. Il trucco è pre-calcolare gli autovalori $\lambda_1, \ldots, \lambda_n$ di $\mathbf{W}$ (costo una tantum $O(n^3)$, ma fatto una sola volta) e poi:

$$\log|\det(\mathbf{I} - \rho\mathbf{W})| = \sum_{i=1}^{n} \log|1 - \rho\,\lambda_i|.$$

Questo costa $O(n)$ per ogni valutazione e permette di ricalcolarlo ad ogni iterazione dell'ottimizzatore senza problemi.

Esempio. Con la nostra $\mathbf{W}$ 4×4, gli autovalori sono $\lambda = (1, 0, 0, -1)$. A $\rho = 0.4$: $\log|\det| = \log|0.6| + \log|1| + \log|1| + \log|1.4| = -0.511 + 0 + 0 + 0.336 = -0.175$.

4.5 L'algoritmo in pratica (TMB)

TMB (Template Model Builder) è un pacchetto R/C++ che implementa tutto questo automaticamente:

1. Si scrive un template C++ che definisce la negative log-joint $f(\boldsymbol{\eta}; \boldsymbol{\theta})$.
2. TMB calcola gradienti e Hessiani tramite **automatic differentiation** (AD): non approssimazioni finite, ma derivate esatte al costo di una singola valutazione.
3. Si dichiara $\boldsymbol{\eta}$ come "random effect": TMB fa automaticamente l'inner loop (Newton per trovare $\hat{\boldsymbol{\eta}}$) e l'outer loop (L-BFGS-B per massimizzare la Laplace approssimata su $\boldsymbol{\theta}$).
4. Gli standard error vengono dal delta method sull'Hessiano della verosimiglianza marginale.

Riparametrizzazioni. Per evitare vincoli durante l'ottimizzazione, lavoriamo su scala trasformata:

- $\rho = \tanh(\tilde{\rho})$, così $\tilde{\rho} \in \mathbb{R} \Rightarrow \rho \in (-1, 1)$;
- $\kappa = \exp(\tilde{\kappa})$, così $\tilde{\kappa} \in \mathbb{R} \Rightarrow \kappa > 0$;
- $\sigma = \exp(\tilde{\sigma})$, così $\tilde{\sigma} \in \mathbb{R} \Rightarrow \sigma > 0$.

TMB riporta automaticamente gli SE sulla scala originale tramite delta method.

5 Effetti diretti, indiretti e totali

Nei modelli spaziali i coefficienti $\boldsymbol{\beta}$ **non sono effetti marginali**. Un cambio di x nel comune j si propaga a tutti i comuni tramite $\mathbf{S}(\rho)$.

5.1 Derivazione

Consideriamo la r-esima covariata. L'effetto di un cambio unitario di x_{jr} su $\mathbb{E}[y_i]$ si ottiene derivando:

$$\frac{\partial\, \mathbb{E}[y_i]}{\partial\, x_{jr}} = (1 - \pi_i)\, \mu_i\, \frac{\partial\, \eta_i}{\partial\, x_{jr}} = (1 - \pi_i)\, \mu_i\, [\mathbf{S}(\rho)]_{ij}\, \beta_r.$$

Qui $[\mathbf{S}(\rho)]_{ij}$ è l'elemento (i, j) del moltiplicatore spaziale.

In forma matriciale, la matrice $n \times n$ degli effetti è:

$$\mathbf{M}_r = \operatorname{diag}\big((1-\boldsymbol{\pi}) \odot \boldsymbol{\mu}\big)\ \mathbf{S}(\rho)\ \beta_r.$$

5.2 Le tre misure sintetiche

- **Effetto diretto medio** = $n^{-1}\operatorname{tr}(\mathbf{M}_r)$ — media degli elementi diagonali: "quanto cambia il mio y se cambio il mio x".
- **Effetto totale medio** = $n^{-1}\mathbf{1}'\mathbf{M}_r\mathbf{1}$ — media delle somme per riga: "quanto cambia il mio y se *tutti* cambiano x".
- **Effetto indiretto medio** = totale − diretto: "quanto del cambio viene dai *vicini*".

Esempio numerico (4×4). Con $\boldsymbol{\eta} = (1.29, 1.52, 1.07, 1.46)'$, $\boldsymbol{\mu} = (3.63, 4.57, 2.92, 4.31)'$, $\boldsymbol{\pi} = (0.31, 0.27, 0.36, 0.29)'$, $\beta_1 = 0.5$ e $\rho = 0.4$:

$$\operatorname{diag}\big((1-\boldsymbol{\pi}) \odot \boldsymbol{\mu}\big) = \operatorname{diag}(2.50, 3.34, 1.87, 3.06).$$

Supponiamo che $\mathbf{S}(0.4)$ sia (approssimata):

$$\mathbf{S}(0.4) \approx \begin{pmatrix} 1.10 & 0.24 & 0.24 & 0.10 \\ 0.24 & 1.10 & 0.10 & 0.24 \\ 0.24 & 0.10 & 1.10 & 0.24 \\ 0.10 & 0.24 & 0.24 & 1.10 \end{pmatrix}.$$

Allora $\mathbf{M}_1 = \operatorname{diag}(\dots) \times \mathbf{S}(0.4) \times 0.5$. L'elemento $(1,1)$ (effetto diretto del comune 1 su sé stesso) è $2.50 \times 1.10 \times 0.5 = 1.375$. L'elemento $(1,2)$ (effetto indiretto: il cambio di x nel comune 2 su y del comune 1) è $2.50 \times 0.24 \times 0.5 = 0.300$.

L'effetto diretto medio $\approx n^{-1}(1.375 + 1.837 + 1.029 + 1.683) = 1.48$. Se $\rho = 0$, l'effetto indiretto sarebbe esattamente zero (la matrice sarebbe diagonale).

6 Proprietà asintotiche

6.1 Consistenza

Lo stimatore è consistente ($\hat{\boldsymbol{\theta}}_n \xrightarrow{p} \boldsymbol{\theta}_0$) sotto condizioni standard. L'argomento è il seguente:

1. L'errore dell'approssimazione di Laplace è $O(n^{-1})$ (Tierney & Kadane 1986). Quindi la log-verosimiglianza approssimata e quella vera convergono uniformemente quando normalizzate per n.

2. La log-verosimiglianza vera, per la legge dei grandi numeri (adattata per dati spazialmente dipendenti ma con dipendenza limitata grazie alla struttura di $\mathbf{W}$), converge al suo valore atteso.

3. Per ipotesi di identificazione, il valore atteso ha un unico massimo in $\boldsymbol{\theta}_0$.

4. Segue consistenza per l'argomento standard degli estimatori di estremo (Newey & McFadden 1994).

6.2 Normalità asintotica

Lo stimatore è asintoticamente normale:

$$\sqrt{n}\,(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \xrightarrow{d} N\big(\mathbf{0},\ \mathcal{I}(\boldsymbol{\theta}_0)^{-1}\big),$$

dove $\mathcal{I}(\boldsymbol{\theta}_0)$ è l'informazione di Fisher per osservazione. Questo giustifica gli intervalli di confidenza e i test di Wald riportati da TMB.

7 Cosa mostrano le simulazioni Monte Carlo

Abbiamo generato dati dal DGP del ZISAR con parametri noti e stimato tre modelli (ZINB, SAR-NB con 2SLS, ZISAR) su 100 repliche per 9 scenari ($n \in \{100, 225, 400\}$, $\rho \in \{0, 0.3, 0.6\}$).

7.1 Risultati principali

1. **Il ZISAR recupera ρ correttamente.** A $n = 400$, $\rho = 0.6$: il bias del ZISAR è -0.007 (praticamente zero), contro -0.479 per il SAR-NB. Il 2SLS non funziona quando ci sono zeri strutturali.

2. **I $\boldsymbol{\beta}$ sono stimati meglio con il ZISAR.** Il ZINB che ignora lo spazio ha bias positivo su β_1 che cresce con ρ ($+0.055$ a $\rho = 0.6$, $n = 400$). Il ZISAR ha bias -0.002.

3. **Il ZISAR ha la migliore verosimiglianza.** Mediana della log-likelihood a $n = 400$, $\rho = 0.6$: ZISAR $= -501$, ZINB $= -884$, SAR-NB $= -887$.

4. **Trade-off κ-σ.** In circa il 10–15% delle repliche, lo stimatore di κ va al bound (l'overdispersion NB viene assorbita dagli effetti random σ^2). Questo è un feno-

meno noto nei modelli NB mixed; nelle applicazioni si può risolvere con prior informative o fissando σ.

8 Riassunto: cosa distingue il ZISAR dai concorrenti

	ZINB	SAR-NB (2SLS)	**ZISAR**
Zero-inflation	✓		✓
Dipendenza spaziale		✓	✓
Effetti random			✓
Stima diretta ρ (ML)			✓
Effetti diretti/indiretti		✓*	✓
No endogeneità	✓		✓

* La decomposizione per il SAR-NB 2SLS è basata su un modello mal specificato (ignora gli zeri strutturali).

Il ZISAR è il primo modello che combina zero-inflation, dipendenza spaziale tipo SAR, ed effetti random in un unico framework, con stima ML tramite Laplace e decomposizione degli effetti.